

# Automotive Sales Prediction

21.11.2022 – Uğur Savcı

# Table of Contents

- Understanding Data
- Data Cleaning & Manipulation
- Exploratory Data Analysis
- Model Building & Prediction

# Data Cleaning & Manipulation

- Standardizasyon olması için bütün sütunlar küçük harf ve boşluklara '\_' eklendi.
- Veri setindeki date sütununun formatını datetime olarak değiştirildi
- Daha sonrasında index olarak atadık.

```
df.columns = df.columns.str.lower().str.replace(" ", "_")
```

```
df = df.iloc[:149,:]
```

```
df['date'] = pd.to_datetime(df['date'], format='%Y/%m/%d')  
df = df.set_index('date')  
df = df.asfreq('MS')  
df = df.sort_index()
```

# Understanding Data

	otv_orani	faiz	eur/tl	kredi_stok	otomotiv_satis
Date					
2010-01-01	37.00	13.18	2.11	341,244.13	20,095.00
2010-02-01	37.00	13.27	2.07	351,940.95	31,172.00
2010-03-01	37.00	12.73	2.09	361,307.32	51,769.00
2010-04-01	37.00	12.01	2.01	373,575.34	54,946.00
2010-05-01	37.00	11.74	1.95	387,708.05	59,377.00

- Elimizdeki veri seti 2010 Ocak ayından başlayıp 2022 Mayıs ayına kadar devam etmektedir.


# Understanding Data

```
<class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 149 entries, 2010-01-01 to 2022-05-01
Freq: MS
Data columns (total 5 columns):
#   Column          Non-Null Count  Dtype
---  -
0   otv_orani        149 non-null    float64
1   faiz             149 non-null    float64
2   eur/tl           149 non-null    float64
3   kredi_stok       149 non-null    float64
4   otomotiv_satis   149 non-null    float64
dtypes: float64(5)
memory usage: 7.0 KB
```

- Herhangi bir eksik veri gözlemi veri setimizde Yok
- Veri tipleri hepsi için float.

# Exploratory Data Analysis

- Otomotiv satışı 2018 'e kadar yatay olarak devam ederken 2018 yılından sonra düşüş gerçekleşti.
- Yılın son aylarında otomotiv satışlarında artış görülürken, Ocak ve şubat aylarında otomotiv satışları genellikle en düşük seviyedeler.



# Feature Engineering

- Modelimizin daha iyi öğrenmesini sağlamak için verimize bazı değişkenler ekleyebiliriz.
- Bunlar ;
- **Tarih değişkenleri** : Yıl, Ay, Hafta, Çeyrek Yılın Haftası, Seri, Mevsim vb
- **Gecikmeli ( Lag ) Değişkenler** : Genellikle hedef değişkenin  $t-1$  bir önceki değeri  $t$  satırına yazılarak yeni bir değişken oluşturulur. ( Period olarak 1 den farklı değerler seçebiliriz.
- **Window değişkenler** : Bu değişkenler hedef değişkenin bir önceki aylardaki aggregate değerleridir. Son 3 aylık ortalama standart sapması vs.

# Feature Engineering

Date değişkenleri olarak eklenen yeni veriler.

## Adding Date Features

```
] : df["month"] = df.index.month  
df["year"] = df.index.year  
df["quarter"] = df.index.quarter  
df['series'] = np.arange(1, len(df)+1)  
df["first_quarter"] = df.quarter.apply(lambda x : 1 if x== 1 else 0)  
df["last_quarter"] = df.quarter.apply(lambda x: 1 if x== 4 else 0)
```

Son 3 ay ortalaması

## Rolling Mean

```
df['rolling_mean_3'] = df['otomotiv_satis'].rolling(3).mean()
```

---



# Exploratory Data Analysis


Correlation Analysis

otv_orani	1	0.32	0.73	0.77	0.091	-0.075	0.74	-0.073	0.74	0.062	-0.03	0.14
faiz	0.32	1	0.69	0.69	-0.37	-0.031	0.7	-0.027	0.7	0.025	-0.027	-0.43
eur/tl	0.73	0.69	1	0.97	-0.17	-0.02	0.85	-0.02	0.85	0.021	0.0093	-0.24
kredi_stok	0.77	0.69	0.97	1	-0.13	0.0019	0.95	0.0017	0.95	-0.00029	0.017	-0.18
otomotiv_satis	0.091	-0.37	-0.17	-0.13	1	0.55	-0.16	0.47	-0.11	-0.39	0.47	0.64
month	-0.075	-0.031	-0.02	0.0019	0.55	1	-0.059	0.97	0.021	-0.75	0.75	0.19
year	0.74	0.7	0.85	0.95	-0.16	-0.059	1	-0.058	1	0.047	-0.034	-0.17
quarter	-0.073	-0.027	-0.02	0.0017	0.47	0.97	-0.058	1	0.02	-0.78	0.77	0.2
series	0.74	0.7	0.85	0.95	-0.11	0.021	1	0.02	1	-0.014	0.026	-0.15
first_quarter	0.062	0.025	0.021	-0.00029	-0.39	-0.75	0.047	-0.78	-0.014	1	-0.34	-0.12
last_quarter	-0.03	-0.027	0.0093	0.017	0.47	0.75	-0.034	0.77	0.026	-0.34	1	0.23
rolling_mean_3	0.14	-0.43	-0.24	-0.18	0.64	0.19	-0.17	0.2	-0.15	-0.12	0.23	1
	otv_orani	faiz	eur/tl	kredi_stok	otiv_satis	month	year	quarter	series	st_quarter	st_quarter	g_mean_3

- Kredi stok ve eur/tl arasında güçlü korelasyon vardır.
- Otomotiv satışı ilk çeyrek ile negatif korelasyona sahip iken last\_quarter ile güçlü pozitif korelasyona sahiptir.

# Model Building & Prediction

## Train-Test Set



- Son 25 Ayı test olarak kullanırken diğer veriler ile modelimizi test edeceğiz.
- Değerlendirme metriği olarak MAPE'yi seçtik.

# Model Building & Prediction

## Lag değişkenlerle birlikte **Baseline Model**

- Baseline model sadece lag değişkenleri ve hedef değişkeninden oluşuyor.
- Modelimizi kurmak için skforecast kütüphanesini kullandık.
- Model recursive olarak bir sonraki periodu hesaplayacaktır.
- Modeli kurarken parametre olarak lag= 15 seçtik. 15 farklı gecikmeli değişken oluşturduk.
- Multicollinearity problemini çözmek adına Regresyon olarak Ridge seçtik.
- Bu şekilde verdiğimiz parametreye göre . Modelin overfit olmasını engellemiş olacağız.

```
forecaster = ForecasterAutoreg(  
    regressor = Ridge(.1),  
    lags      = 15  
    |  
)  
  
forecaster.fit(  
    y = data_train['otomotiv_satis'],  
    )
```

# Model Building & Prediction

## Prediction


```
steps = 25  
predictions = forecaster.predict(steps)
```

## Test Error

```
error_mape = mean_absolute_percentage_error(  
    y_true = data_test['otomotiv_satis'],  
    y_pred = predictions  
)
```

```
print(f"Test error (mape):% {round((error_mape),3)*100}")
```

Output : **%20.9**



# Model Building & Prediction

## Prediction


```
steps = 25  
predictions = forecaster.predict(steps)
```

## Test Error

```
error_mape = mean_absolute_percentage_error(  
    y_true = data_test['otomotiv_satis'],  
    y_pred = predictions  
)
```

```
print(f"Test error (mape):% {round((error_mape),3)*100}")
```

Output : **%20.9**




# Model Building & Prediction

## Model with Features

```
steps = 25  
predictions2 = forecaster2.predict(steps=steps,exog = data_train[features])
```

```
error_mape = mean_absolute_percentage_error(  
    y_true = data_test['otomotiv_satis'],  
    y_pred = predictions2  
)  
  
print(f"Test error (mape):% {round((error_mape),2)*100}")
```

Output : %30.1



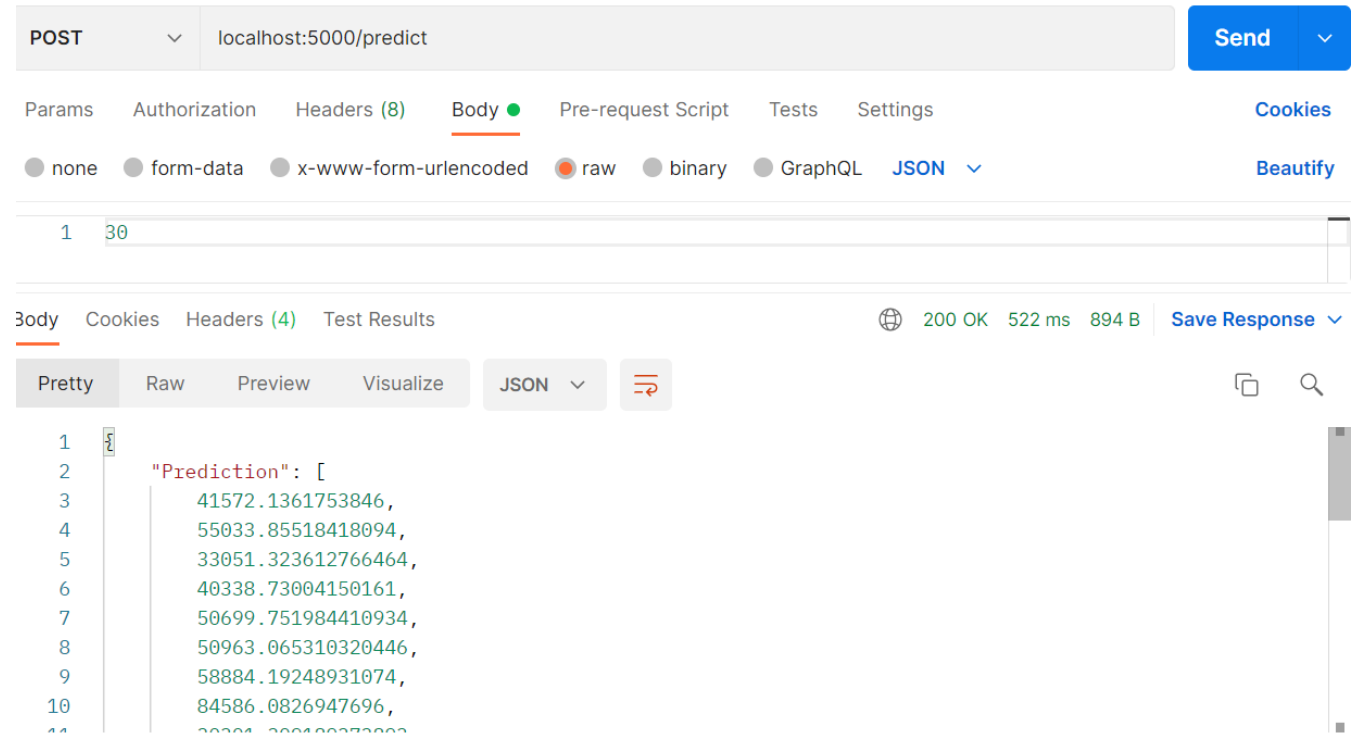
# Prediction

- Sadece lag olan modelimizin performansı daha iyi çıktı.
- Modele göre Haziran – 2022 – 2023 dönemleri için tahminleri aldık.

	pred
2022-06-01	75334.973713
2022-07-01	52062.950842
2022-08-01	58188.335866
2022-09-01	63357.121213
2022-10-01	58267.150301
2022-11-01	67341.510781
2022-12-01	83157.501533
2023-01-01	40809.398093
2023-02-01	62600.433519
2023-03-01	69504.188992
2023-04-01	51513.808668
2023-05-01	68812.428978
2023-06-01	75696.384310

# Postman API Testing

- Flask ile rest api kuruldu ve api test edildi.
- Kaç ay sonrasını tahmin etmek istiyor isek modele sadece sayı(period) olarak vermemiz yeterli oluyor.





# Model Deployment

- Modeli deploy etmek için Dockerfile ve requirements.txt oluşturdum.
- Ancak aws ec2 instancetabir çok kez denememe rağmen private key hatası aldığım için maalesef deploy edemedim.
- Fakat deployment ile ilgili daha önce yaptığım çalışmanın linkini buraya bırakıyorum.
- <https://churnpredictionapp1.herokuapp.com/>

Anlayışınız için şimdiden teşekkür ederim.